

Εφαρμοσμένη Επιστήμη Δεδομένων

Εαρινό Εξάμηνο 2026

Ομαδική Εργασία: AI for Epigraphy — Ανάλυση Εικόνων και Κειμένων Αρχαίων Ελληνικών Επιγραφών

Πεδίο	Στοιχεία
Μάθημα	Εφαρμοσμένη Επιστήμη Δεδομένων
Υπεύθυνοι	Βίβιαν Πλατάνου (platanou@aueb.gr), Οδυσσέας Χλαπάνης (odyhlapanis@aueb.gr)
Ημερομηνία Παράδοσης	[ΗΗ/ΜΜ/2026], 23:55
Υποβολή	e-Class
Μορφή	Ομαδική εργασία (2 ατόμων)
Χρήση AI/LLM	Επιτρέπεται — βλ. οδηγίες στο τέλος

Περιγραφή

Σε αυτή την εργασία θα σχεδιάσετε ένα πλήρες υπολογιστικό pipeline για την ανάλυση αρχαίων ελληνικών επιγραφών. Το σύνολο δεδομένων αποτελεί μέρος του ICDAR 2026 Competition in Text Recognition on Greek Squeezes και είναι διαθέσιμο στη διεύθυνση: <https://www.science.smith.edu/~nhowe/contest/trogs26.html#dataset>

Τα δεδομένα περιλαμβάνουν μεταγραφές κειμένων εικόνων (λατινικοί χαρακτήρες που αναπαριστούν ελληνικό κείμενο) σε συνεχόμενη γραφή (scriptio continua, χωρίς διαχωρισμό λέξεων) και τις αντίστοιχες εικόνες επιγραφών (squeezes).

Τα squeezes είναι τρισδιάστατα χάρτινα αποτυπώματα λίθινων επιγραφών — μια μορφή ιστορικού εγγράφου όπου οι ψηφιακές μέθοδοι επεξεργασίας έχουν μελετηθεί ελάχιστα.

Πρόκειται για εργασία 2 ατόμων. Καλείστε να απαντήσετε και στα δύο μέρη (Α και Β) της εργασίας. Η συμμετοχή στο ICDAR Competition είναι προαιρετική και επιβραβεύεται.

Το notebook εκκίνησης (team_notebook.ipynb) περιλαμβάνει κώδικα φόρτωσης δεδομένων, βασικές οδηγίες εγκατάστασης, και τις ερωτήσεις κάθε μέρους.

Howe, N.R., Chang, F., Falbo, I., Brown, T. & Hershkowitz, A. "Character Recognition for Greek Squeezes." IJDAR 28, 345–356 (2025).

Δεδομένα

Τα δεδομένα βρίσκονται στον σύνδεσμο του διαγωνισμού και αποτελούνται από:

Αρχεία Μεταγραφών (Annotations)

Αρχεία κειμένου (.txt) που περιέχουν μεταγραφές επιγραφών σε λατινικούς χαρακτήρες (Latin characters representing Greek text). Οι μεταγραφές είναι σε μορφή scriptio continua — δηλαδή χωρίς κενά μεταξύ λέξεων. Στον φάκελο Annotations υπάρχει επίσης ένα βοηθητικό αρχείο PDF (Proxies) με πίνακα αντιστοίχισης λατινικών–ελληνικών χαρακτήρων.

Εικόνες Squeezes (Images)

Εικόνες squeeze σε μορφή .png, που αντιστοιχούν στις μεταγραφές μέσω κοινού αναγνωριστικού (inscription_id). Κάθε εικόνα απεικονίζει ένα χάρτινο αποτύπωμα λίθινης επιγραφής.

Μέρος Α — Ανάλυση Κειμένων (50 μονάδες)

A1. Μετατροπή Λατινικών σε Ελληνικούς Χαρακτήρες (6 μονάδες)

Μετατρέψτε τους λατινικούς χαρακτήρες των μεταγραφών σε κεφαλαία ελληνικά γράμματα (δεν απαιτούνται τόνοι/πνεύματα), ώστε οι μεταγραφές να γίνουν αναγνώσιμο αρχαίο ελληνικό κείμενο.

- Μπορείτε να χρησιμοποιήσετε το βοηθητικό αρχείο PDF "Proxies" που βρίσκεται στον φάκελο Annotations.
- Περιγράψτε το σύστημα μεταγραφής σας (transliteration system) και παρέχετε παραδείγματα πριν/μετά τη μετατροπή.

A2. Τμηματοποίηση Λέξεων — Word Segmentation (10 μονάδες)

Οι μεταγραφές δεν περιέχουν κενά μεταξύ λέξεων (scriptio continua). Προτείνετε και υλοποιήστε μια στρατηγική τμηματοποίησης.

- Εξηγήστε τη μέθοδό σας, παρουσιάστε παραδείγματα, και συζητήστε τις προκλήσεις.
- Hint: Για την κατασκευή λεξιλογίου μπορείτε να χρησιμοποιήσετε: `ds = load_dataset("Ericu950/Papyri_1", split="train", streaming=True)`

A3. Μέγεθος Λεξιλογίου & Συχνότητα Λέξεων (6 μονάδες)

Υπολογίστε το μέγεθος του λεξιλογίου, εντοπίστε τις πιο συχνές λέξεις και ανιχνεύστε σπάνιες λέξεις.

- Απεικονίστε τα αποτελέσματά σας με κατάλληλα γραφήματα.

A4. Κύρια Ονόματα (6 μονάδες)

Εξερευνήστε τα κύρια ονόματα που εμφανίζονται στις επιγραφές σας.

- Παρέχετε γραφήματα κατανομής συχνότητας ανά φύλο (gender).

A5. Ομαδοποίηση Επιγραφών & Θεματική Ανάλυση (10 μονάδες)

Ομαδοποιήστε (cluster) τις επιγραφές και απαντήστε στα εξής ερωτήματα:

- α. Αντιστοιχούν τα clusters σε ομοιότητες στη δομή κειμένου;

- β. Περιλαμβάνουν τα clusters επαναλαμβανόμενες φράσεις;
- γ. Εμφανίζονται συγκεκριμένα θέματα σε κάθε cluster;

Χρησιμοποιήστε κατάλληλες μεθόδους topic modeling για να απαντήσετε στο τελευταίο ερώτημα.

A6. Χρονολόγηση με Aeneas & Σύγκριση με LLM (12 μονάδες)

Δεν υπάρχουν γνωστές χρονολογίες (ground-truth dates) για τις επιγραφές αυτού του dataset.

1. Χρησιμοποιήστε το προ-εκπαιδευμένο σε επιγραφές μοντέλο Aeneas (<https://github.com/google-deepmind/predictingthepast>) για να προβλέψετε τις χρονολογίες 10 επιγραφών.
2. Στη συνέχεια, συγκρίνετε τις προβλέψεις με αυτές ενός γενικού (general-purpose) LLM της επιλογής σας.
3. Σε κελί markdown: Συγκρίνετε τα αποτελέσματα. Μπορούν τα γενικά LLMs να χρησιμοποιηθούν αποτελεσματικά από ιστορικούς για χρονολόγηση; Ποιο μοντέλο ήταν καλύτερο και γιατί;
4. Υπάρχει κάτι κοινό στα σφάλματα (common failure) μεταξύ των μοντέλων AI;

Assael, Y. et al. "Restoring and attributing ancient texts using deep neural networks." Nature 603, 280–283 (2022).

Μέρος B — Ανάλυση Εικόνων (50 μονάδες)

B1. Προεπεξεργασία Εικόνων (12 μονάδες)

Σε αυτό το μέρος καλείστε να πραγματοποιήσετε Αναγνώριση Κειμένου (Text Recognition) από τις εικόνες του dataset. Πρώτα, παρέχετε δειγματικές απεικονίσεις των βημάτων προεπεξεργασίας εικόνων σας. Στόχος είναι ο καθαρισμός των εικόνων και η μείωση θορύβου. Πρέπει να δείξετε:

- i. Τις αρχικές εικόνες/δείγματα
- ii. Τα βήματα προεπεξεργασίας στα ίδια δείγματα
- iii. Τις καθαρισμένες εικόνες

B2. Ομαδοποίηση Εικόνων μέσω Embeddings (16 μονάδες)

Χρησιμοποιήστε embeddings από ένα οπτικό μοντέλο (visual model) για να ομαδοποιήσετε τις εικόνες βάσει οπτικής ομοιότητας και παρέχετε κατάλληλη απεικόνιση στον χώρο εικόνων. Λάβετε υπόψη τον μεγάλο αριθμό εικόνων.

Οδηγίες:

- Εξαγάγετε embeddings από ένα οπτικό μοντέλο (π.χ. ViT).
- Χρησιμοποιήστε PCA και UMAP για ομαδοποίηση και απεικόνιση.

- Εκτυπώστε εικόνες κοντά στα κεντροειδή κάθε cluster (π.χ. 3 εικόνες ανά κεντροειδές).
- Ονομάστε τα θέματα (topics) 3 clusters και σχολιάστε — χρησιμοποιήστε τα filenames για να ελέγξετε αν ανήκουν στην ίδια εποχή.
- Χρησιμοποιήστε ένα LLM για να αυτοματοποιήσετε την ονοματοδοσία θεμάτων.
- Αναλύστε: Βρίσκονται ζεύγη εικόνων στο ίδιο cluster; Βρίσκονται εικόνες από τον ίδιο τόπο/αρχείο στο ίδιο cluster;

B3. Pipeline Αναγνώρισης Κειμένου (22 μονάδες)

Κατασκευάστε και αξιολογήστε ένα pipeline αναγνώρισης κειμένου. Αυτή η εργασία αντιστοιχεί στο ICDAR 2026 Competition in Text Recognition on Greek Squeezes. Οι επιλογές περιλαμβάνουν:

- Transformer-based OCR
- Προ-εκπαιδευμένα Vision Language Models (VLMs)

Αξιολογήστε χρησιμοποιώντας Character Error Rate (CER) σε λατινικούς χαρακτήρες, όπως ακριβώς γίνεται στον επίσημο διαγωνισμό.

Baseline μοντέλα αναφοράς:

- TrOCR — Li et al. "TrOCR: Transformer-based OCR with Pre-trained Models." AAAI 2022. arXiv:2109.10282. Μοντέλα: microsoft/trocr-base-printed
- ViTSTR — Atienza, R. "Vision Transformer for Fast and Efficient Scene Text Recognition." ICDAR 2021. arXiv:2105.08582

Στο notebook παρέχεται μια baseline λύση που μπορείτε να χρησιμοποιήσετε ως αφετηρία. Χρησιμοποιήστε το script αξιολόγησης του διαγωνισμού (παρέχεται σε κελί στο notebook) για να αξιολογήσετε τόσο το baseline όσο και τη δική σας λύση, και δείξτε τη βελτίωση.

Παραδοτέα

Υποβάλετε τα ακόλουθα αρχεία στο e-Class:

Αρχείο	Περιγραφή
<AM1>_<AM2>.ipynb (ή .py)	Αρχεία κώδικα με ονομασία βάσει αριθμών μητρώου. Το notebook πρέπει να έχει εκτελεστεί πλήρως (Kernel → Restart & Run All).
<AM1>_<AM2>_report.pdf	Αναφορά 5–6 σελίδων σε μορφή PDF, που περιλαμβάνει τις μεθόδους, τα πειράματα (περιγραφές και γραφήματα) και τη συζήτηση.
prompts_<AM1>_<AM2>.m	Βιβλιοθήκη prompts — υποχρεωτικό παραδοτέο (βλ. οδηγίες παρακάτω).

Αρχείο	Περιγραφή
ICDAR 2026 (προαιρετικό)	Μονοσέλιδο έγγραφο με το submitted group name σας στο ICDAR 2026 Competition. Η συμμετοχή επιβραβεύεται με +10% στον βαθμό της εργασίας. Επιπλέον, αν βρεθείτε στους top-20 του διαγωνισμού, λαμβάνετε +10% στον τελικό βαθμό του μαθήματος.

Σημείωση: Χρησιμοποιήστε κελιά *markdown* μέσα στο *notebook* για τα σχόλια και τα συμπεράσματά σας. Κάθε μέλος πρέπει να αναφέρει σε κελί *markdown* στην αρχή του *notebook* τη συνεισφορά του σε κάθε μέρος.

Κριτήρια Αξιολόγησης

Μέρος	Μονάδες
A — Ανάλυση Κειμένων	50
B — Ανάλυση Εικόνων	50
Σύνολο	100
Ποιότητα κώδικα & <i>markdown</i> σχόλια	+5
Συμμετοχή στο ICDAR 2026 Competition	+10% στον βαθμό της εργασίας
Top-20 στο ICDAR 2026 Competition	+10% στον τελικό βαθμό του μαθήματος

Χρήση Εργαλείων Τεχνητής Νοημοσύνης (LLMs)

Η χρήση εργαλείων τεχνητής νοημοσύνης (π.χ. ChatGPT, GitHub Copilot, Claude, Gemini κ.ά.) επιτρέπεται και ενθαρρύνεται ως εργαλείο μάθησης και παραγωγικότητας. Ωστόσο, είναι υποχρεωτική η τεκμηρίωση της χρήσης τους μέσω μιας βιβλιοθήκης *prompts* που υποβάλλεται μαζί με την εργασία.

Οδηγίες:

- Χρησιμοποιήστε το `template_prompts.md` ως πρότυπο και υποβάλετε το αρχείο σας με όνομα `prompts_<AM1>_<AM2>.md`.
- Κρατήστε ένα ημερολόγιο αλληλεπιδράσεων με AI καθ' όλη τη διάρκεια εκπόνησης της εργασίας. Κάθε φορά που ολοκληρώνετε μια ενότητα, ενημερώστε τον πίνακα στο `template` με την ημερομηνία, την ενότητα, και μια σύντομη περιγραφή.
- Συγκεκριμένα, για κάθε φορά που χρησιμοποιείτε ένα LLM θα πρέπει να καταγράψετε:

- Σε ποιο ερώτημα/μέρος της εργασίας αναφέρεται.
 - Ποιο εργαλείο χρησιμοποιήσατε (π.χ. Claude Code, ChatGPT, GitHub Copilot, Cursor).
 - Ποιο μοντέλο έτρεχε πίσω από το εργαλείο (π.χ. Claude Sonnet 4.6, GPT-4o, Gemini 2.5 Pro).
 - Το ακριβές prompt που δώσατε.
8. Το αρχείο `prompts_<AM1>_<AM2>.md` αποτελεί υποχρεωτικό παραδοτέο και υποβάλλεται μαζί με τα υπόλοιπα αρχεία στο e-Class.

Επιτρεπόμενες Βιβλιοθήκες

pandas, numpy, matplotlib, seaborn, scikit-learn, scipy, Pillow, OpenCV, torch/torchvision, tensorflow/keras, transformers, datasets, accelerate, sentencepiece, nltk, cltk, requests, wordcloud, umap-learn, jax/flax

Μπορείτε να χρησιμοποιήσετε επιπλέον βιβλιοθήκες εφόσον τις τεκμηριώνετε στο notebook (σε κελί markdown στην αρχή). Δεν επιτρέπεται η αντιγραφή έτοιμων λύσεων.

Άδεια Χρήσης Δεδομένων

Πηγή	Άδεια	Απαίτηση
ICDAR 2026 / Smith College Dataset	CC-BY 4.0	Υποχρεωτική αναφορά στην πηγή
Aeneas (DeepMind)	Apache 2.0	Αναφορά πηγής

Στο notebook σας πρέπει να δηλώσετε τις πηγές δεδομένων και τις αντίστοιχες άδειες χρήσης σε κελί markdown, συμπεριλαμβάνοντας:

Howe, N.R., Chang, F., Falbo, I., Brown, T. & Hershkowitz, A. "Character Recognition for Greek Squeezes." IJDAR 28, 345–356 (2025).

Πηγές Δεδομένων & Αναφορές

- ICDAR 2026 Competition — Text Recognition on Greek Squeezes: <https://www.science.smith.edu/~nhowe/contest/trogs26.html>
- Character Recognition for Greek Squeezes — Annotated Data (Smith College): https://scholarworks.smith.edu/dds_data/18
- Aeneas (Predicting the Past) — DeepMind: <https://github.com/google-deepmind/predictingthepast>
- TrOCR — Microsoft: <https://arxiv.org/abs/2109.10282>
- ViTSTR — Atienza: <https://arxiv.org/abs/2105.08582>

- CLTK (Classical Language Toolkit): <https://github.com/cltk/cltk>